

Erro quadrático para o input x :

$$E_D[(f(x;D) - E[y|x])^2] \quad (I)$$

Onde $f(x;D)$ é o modelo de predição treinado em D para o input x , resultante em \hat{y} .

y é o output esperado

$E[y|x]$ é a esperança ideal

Expondo-se (I) ao adicionar e subtrair

$$E_D[f(x;D)]$$

$$(I) = E_D[(f(x;D) - E_D[f(x;D)] + E_D[f(x;D)] - E[y|x])^2]$$

Expandindo o quadrado

$$= E_D[(f(x;D) - E_D[f(x;D)])^2 +$$

$$2.(f(x;D) - E_D[f(x;D)])(E_D[f(x;D)] - E[y|x]) +$$

$$(E_D[f(x;D)] - E[y|x])^2]$$

Como $E_D[f(x;D)]$ é cte em D

viés quadrático (A)

$$E_D[(f(x;D) - E[y|x])^2] = (E_D[f(x;D)] - E[y|x])^2 +$$

$$E_D[(f(x;D) - E_D[f(x;D)])^2]$$

La Variância (B)

(A). O viés quadrático exprime a distância/desvio do output do modelo em relação à função real.

↳ Pode indicar uma "super simplificação" do modelo, gerando underfitting.

(B). Mede a flutuação das predições do modelo de acordo com diferentes datasets (D).

↳ Pode indicar uma "super sensibilidade" do modelo, resultando em overfitting.

Agora, decompondo o erro total

$$E_D E_y [(f(x; D) - y)^2], \text{ (II)}$$

Expandindo-se y com $E[y|x]$

$$\text{(II)} = E_D E_y [(f(x; D) - E[y|x] + E[y|x] - y)^2]$$

Expandindo o quadrado

$$E_D E_y [(f(x; D) - E[y|x])^2 + 2 \cdot (f(x; D) - E[y|x]) \cdot (E[y|x] - y) + (E[y|x] - y)^2]$$

Como em y , $E_y[E[y|x] - y] = 0$

$$= \underbrace{E_D [(f(x; D) - E[y|x])^2]}_{\text{(I)}} + E_y [(E[y|x] - y)^2]$$

Substituindo a decomposição de (I) na decomposição de (II).

→ (A) viés

$$(II) = (E_D[f(x; D)] - E[y|x])^2 + E_D[(f(x; D) - E_D[f(x; D)])^2] + E_y[(E[y|x] - y)^2]$$

→ (B) variância do família de modelos

→ (C) variância residual

(C) É a variância resultante (e "irredutível") do ruído inerente às amostras.

→ Gerado por imprecisões de medição, variáveis não incluídas em x , aleatoriedades etc...